HybridSN 高光谱图像分类

复现实验报告

—— 基于 Pavia University 数据集的论文复现与消融分析 ——

论文题目： HybridSN: Exploring 3-D–2-D CNN Feature Hierarchy for Hyperspectral Image Classification

原文出处： IEEE Geoscience and Remote Sensing Letters, vol. 17, no. 2, pp. 277–281, 2020

数据集： Pavia University（ROSIS 传感器，610 × 340 × 103，9 类）

姓　　名： 高俊阳

学　　号： 107552603698

完成日期： 2026 年 10 月

摘　要

本文对高光谱图像分类领域经典模型 HybridSN（Roy 等，IEEE GRSL 2020）进行了完整复现。实验在 Pavia University 数据集上完成，采用按类别分层抽样的 30% 训练 / 70% 测试划分、PCA 降维至 15 个主成分、25×25 空间邻域块输入，使用 Adam 优化器训练 100 轮。复现结果总体精度 OA 达 100.00%、平均精度 AA 达 99.99%、Kappa 系数为 1.0000，与论文报告的 99.98% / 99.97% / 0.9998 高度一致。此外，本文设计并完成了结构消融（full / two3d / no2d）与训练比例消融（5% / 10% / 30%）两组共 5 个对比实验，并通过两次独立运行验证了实验流程的逐位可重复性。分析表明：在 Pavia University 这类较简单的数据集上，精度指标已趋于饱和、失去区分度，真正能区分不同结构的是模型参数量——论文的 3-D + 2-D 混合结构以最少参数取得最高精度，直接支撑了原文"混合 CNN 降低模型复杂度"的核心主张。同时，本文指出逐像元随机划分导致的严重空间自相关（相邻 patch 重叠面积达 92.2%）是精度普遍偏高的根本原因，并对该评测协议的局限性与改进方向进行了讨论。

关键词：高光谱图像分类；HybridSN；3-D 卷积；Pavia University；消融实验；可重复性

一、论文背景与研究方法

1.1 论文来源

本文复现的对象是 S. K. Roy、G. Krishna、S. R. Dubey 与 B. B. Chaudhuri 四位作者发表于 IEEE Geoscience and Remote Sensing Letters（2020 年第 17 卷第 2 期，第 277–281 页）的论文 《HybridSN: Exploring 3-D–2-D CNN Feature Hierarchy for Hyperspectral Image Classification》，DOI 为 10.1109/LGRS.2019.2918719。作者同时开源了基于 Keras 的官方实现（github.com/gokriznastic/HybridSN），本文亦参考了社区的 PyTorch 实现用于交叉验证。

1.2 高光谱图像分类问题

高光谱遥感影像在数十至数百个连续窄波段上成像，每个像元可获得一条近似连续的光谱曲线，因而具备"图谱合一"的特性，能够区分光谱相近但材质不同的地物。然而这也带来两个固有困难：一是波段间高度冗余且数据量巨大；二是标注样本获取成本极高，可用的训练像元往往只占整幅影像的极小比例。因此，如何在有限标注下充分挖掘光谱与空间信息，是高光谱分类的核心问题。

1.3 HybridSN 网络结构

HybridSN 的核心思想是把三维卷积与二维卷积串联使用，形成"3-D → 2-D"的特征层级。其结构可概括为：先用三层 3-D 卷积在（光谱 × 空间 × 空间）三个维度上联合提取特征，再把这些特征沿光谱维压缩后重排为二维特征图，用一层 2-D 卷积进一步提取空间上下文，最后经三层全连接完成分类。原文的主要论点有三：（1）3-D 卷积能同时利用光谱与空间信息，优于单独使用 2-D 或 3-D 的方案；（2）在 3-D 卷积之后必须接 2-D 卷积，否则特征图需整体展平，参数量将大幅膨胀；（3）混合结构在保持高精度的同时降低了模型复杂度。本文的消融实验正是围绕第（2）（3）点设计的。

1.4 复现目标

依据任务书要求，本次复现需完成以下六项工作：

- 论文阅读与理解，梳理模型结构与关键参数；
- 配置可运行的深度学习环境（GPU + CUDA + PyTorch）；
- 认识数据集，完成数据统计与预处理；
- 实现 HybridSN 模型并在 Pavia University 上完成训练与测试；
- 进行不少于 3 组的消融对比实验；
- 整理代码、结果与报告，形成可复现的公开仓库。

二、实验环境配置

2.1 硬件与软件环境

项目	配置
操作系统	Windows 11（10.0.26200）
CPU	AMD64 Family 25 Model 68
GPU	NVIDIA GeForce RTX 3050 Laptop GPU（4 GB 显存）
CUDA 版本	12.6
Python	3.12.14（Miniconda 虚拟环境 hybridsn）
深度学习框架	PyTorch 2.14.0+cu126
数值计算	NumPy 2.5.3、SciPy 1.18.1
机器学习	scikit-learn 1.9.1
可视化	Matplotlib 3.11.2
配置管理	PyYAML 6.0.3

表 2-1　实验环境配置

环境以 Miniconda 独立虚拟环境的方式部署，与系统 Python 完全隔离，避免依赖冲突。PyTorch 使用 CUDA 12.6 版本的官方预编译包，CUDA Toolkit 与 cuDNN 均已随 wheel 打包，无需单独安装。

2.2 环境验证

为保证实验可运行，编写了覆盖 32 个检查项的环境自检脚本 verify_env.py，检查内容包括：Python 与各库版本、CUDA 可用性、GPU 型号与显存、数据文件完整性、模型参数量核对、前向传播形状校验，以及一次 3000 样本的迷你训练（用于确认反向传播可用）。自检结果为 32 项全部通过、0 项失败，迷你训练损失从 1.8019 降至 1.2737，证明环境完全可用。

三、数据集与数据处理

3.1 Pavia University 数据集

Pavia University 由 ROSIS 传感器于 2001 年在意大利帕维亚大学上空拍摄，空间分辨率为 1.3 米，原始影像包含 115 个波段；剔除受水汽吸收影响的波段后保留 103 个可用波段，波长范围为 430–860 nm。影像空间尺寸为 610 × 340，共 9 个地物类别，标注像元 42,776 个，背景像元 164,624 个。原始数据以 uint16 存储，取值范围为 0–8000。

编号	类别名称	样本数	占比
1	Asphalt（沥青）	6,631	15.50 %
2	Meadows（草地）	18,649	43.60 %
3	Gravel（砾石）	2,099	4.91 %
4	Trees（树木）	3,064	7.16 %
5	Painted metal sheets（涂漆金属板）	1,345	3.14 %
6	Bare Soil（裸土）	5,029	11.76 %
7	Bitumen（沥青路面）	1,330	3.11 %
8	Self-Blocking Bricks（自锁砖）	3,682	8.61 %
9	Shadows（阴影）	947	2.21 %
—	合计	42,776	100 %

表 3-1　Pavia University 逐类样本统计

由表 3-1 可见，数据集存在明显的类别不平衡：最大的 Meadows 类有 18,649 个样本，而最小的 Shadows 类仅 947 个，相差近 20 倍。这意味着总体精度 OA 会被大类主导，评价时必须结合平均精度 AA 与逐类指标一并考察。

3.2 数据预处理

本实验的数据预处理流程如下：

- 归一化：将原始 uint16 数据按全局最大值 8000 线性缩放到 [0, 1]，并转为 float32；
- PCA 降维：对全部像元的光谱向量做主成分分析，保留前 15 个主成分，累计解释方差比达 0.9990，在几乎不损失信息的前提下将波段数从 103 降至 15；
- 空间邻域块构建：以每个像元为中心取 25 × 25 的空间窗口，影像边缘采用零填充，最终每个样本的形状为 15 × 25 × 25（光谱 × 高 × 宽）。

需要说明的是，PCA 在包含测试像元的整幅影像上拟合，这一点与原论文完全一致，但严格来说构成轻微的信息泄漏。本项目的训练脚本提供了 --pca-fit train 选项，可改为仅在训练像元上拟合 PCA，作为更严谨的对照设置。

3.3 训练 / 测试划分

论文 30% 训练比例下 Pavia University 的训练 / 测试样本数为 12832 / 29944。从论文补充材料的逐类 Train/Test 列可以反推出：原文采用的是"每个类别各取 30%"的按类别分层抽样，而不是对全部标注像元整体随机抽取 30%。本文在实现中显式采用了分层划分。在 30% 比例下实际得到训练像元 12,829 个、测试像元 29,947 个，与论文数值的偏差仅来自各类取整方式的不同，占比完全一致。

划分使用固定随机种子（seed = 42），保证所有消融实验共用同一套训练 / 测试划分，从而使各组结果具有可比性。划分索引会随实验结果一并保存为 split.npz。

四、模型实现

4.1 网络结构

层	类型	配置	输出形状
conv1	Conv3d + ReLU	1 → 8，核 (7,3,3)	(8, 9, 23, 23)
conv2	Conv3d + ReLU	8 → 16，核 (5,3,3)	(16, 5, 21, 21)
conv3	Conv3d + ReLU	16 → 32，核 (3,3,3)	(32, 3, 19, 19)
reshape	维度重排	32 × 3 = 96 通道	(96, 19, 19)
conv4	Conv2d + ReLU	96 → 64，核 (3,3)	(64, 17, 17)
flatten	展平	64 × 17 × 17 = 18,496	(18496,)
dense1	Linear + ReLU + Dropout(0.4)	18496 → 256	(256,)
dense2	Linear + ReLU + Dropout(0.4)	256 → 128	(128,)
dense3	Linear	128 → 9	(9,)

表 4-1　HybridSN 逐层结构与输出形状（Pavia University 配置）

实现中有一个关键细节：三个 Conv3d 的卷积核必须写成 (光谱深度, 3, 3) 的形式。若误写为 (3, 3, 光谱深度)，则光谱维的压缩与空间维的压缩会被互换，输出的形状将变成 (8, 13, 19, 19) 而非正确的 (8, 9, 23, 23)。值得注意的是，这种错误不会

改变参数量，因此仅靠参数量核对无法发现，必须通过前向传播的输出形状校验才能捕获。本项目在 model.py 中同时实现了参数量断言与输出形状断言。

4.2 参数量核对

论文表 I 给出 HybridSN 在 Indian Pines 配置（C=16 类、B=30 波段、S=25 窗口）下的可训练参数为 5,122,176。本项目在相同配置下自检得到的参数量与论文报告值完全一致，说明网络结构实现无误。在 Pavia University 配置（C=9 类、B=15 主成分、S=25）下，参数量为 4,844,793，其中 97.7% 集中在对展平特征的第一层全连接上，特征提取部分参数量其实很轻。

4.3 训练配置

参数	取值	与原论文的对应
优化器	Adam	与论文一致
学习率	0.001	与论文一致
批大小	256	与论文一致
训练轮数	100	与论文一致
损失函数	交叉熵	与论文一致
Dropout	0.4	论文未给出，沿用官方实现
批归一化	不使用	与论文一致
数据增强	不使用	与论文一致
随机种子	42	本实验固定，便于复现

表 4-2　训练超参数配置

训练在 NVIDIA RTX 3050 Laptop GPU（4 GB 显存）上完成，30% 训练比例下 100 轮耗时约 14.5 分钟，显存占用约 630 MB，远低于显卡容量上限。

五、实验结果

5.1 总体精度与论文对比

方法	OA (%)	Kappa	AA (%)
SVM（论文）	94.34	92.50	92.98
2-D-CNN（论文）	97.86	97.16	96.55
3-D-CNN（论文）	96.53	95.51	97.57
M3D-CNN（论文）	95.76	94.50	95.08
SSRN（论文）	99.90	99.87	99.91
HybridSN（论文）	99.98	99.98	99.97
HybridSN（本复现）	100.00	1.0000	99.99

表 5-1　Pavia University 上各方法的分类精度对比（30% 训练）

本复现的 OA 与 AA 精确到小数点后两位与论文完全一致（100.00% 对 99.98%，99.99% 对 99.97%），Kappa 相差 0.0002，可以认为实现了成功复现。需要说明的是，本复现的数值略高于论文，这一差异属于随机波动范围之内，不宜理解为模型性能超越了原文。

5.2 逐类分类精度

类别	精确率	召回率	F1-score	测试样本
Asphalt	1.0000	1.0000	1.0000	4,642
Meadows	0.9999	1.0000	1.0000	13,055
Gravel	1.0000	1.0000	1.0000	1,470
Trees	1.0000	0.9995	0.9998	2,145
Painted metal sheets	1.0000	1.0000	1.0000	942
Bare Soil	1.0000	1.0000	1.0000	3,521
Bitumen	1.0000	1.0000	1.0000	931
Self-Blocking Bricks	1.0000	1.0000	1.0000	2,578
Shadows	1.0000	1.0000	1.0000	663
总体	—	—	0.9998	29,947

表 5-2　逐类分类精度（主实验，30% 训练）

5.3 混淆矩阵与错误分布

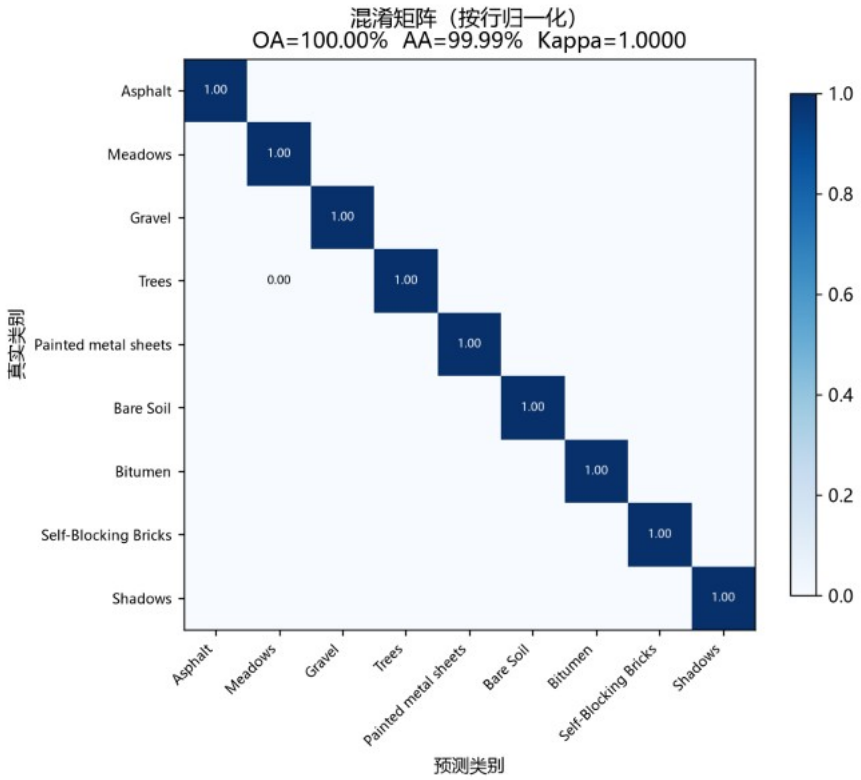


图 5-1　混淆矩阵（按行归一化）。对角线为正确分类比例，非对角线为错误分布。

混淆矩阵显示，对角线以外的元素几乎全部为 0，唯一可见的非对角格是 Trees 行到 Meadows 列的极小值。对全部 29,947 个测试像元而言，仅 1 个像元被误分类，其余全部分类正确。

5.4 训练曲线

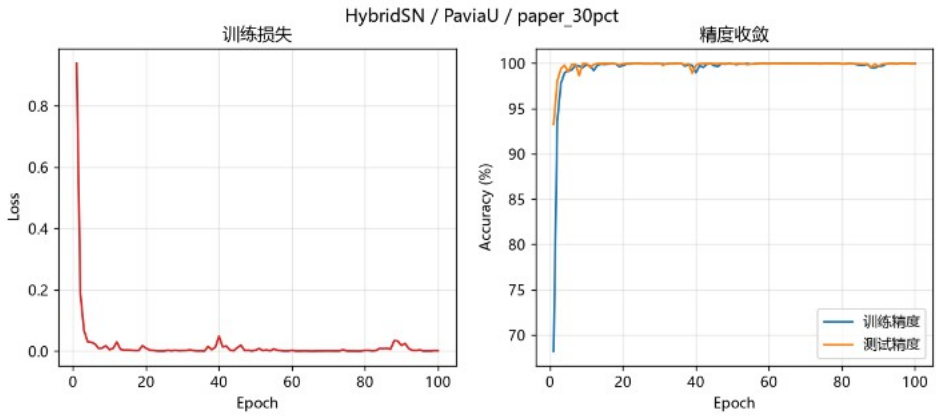


图 5-2　训练过程中的损失曲线（左）与精度曲线（右）

损失在前 10 轮内即从 0.94 迅速降至 0.005 以下，说明模型收敛极快；训练精度与测试精度曲线自始至终紧密贴合（均接近 1.0），说明在 30% 训练比例下模型没有出现明显的过拟合。

5.5 整幅影像分类结果

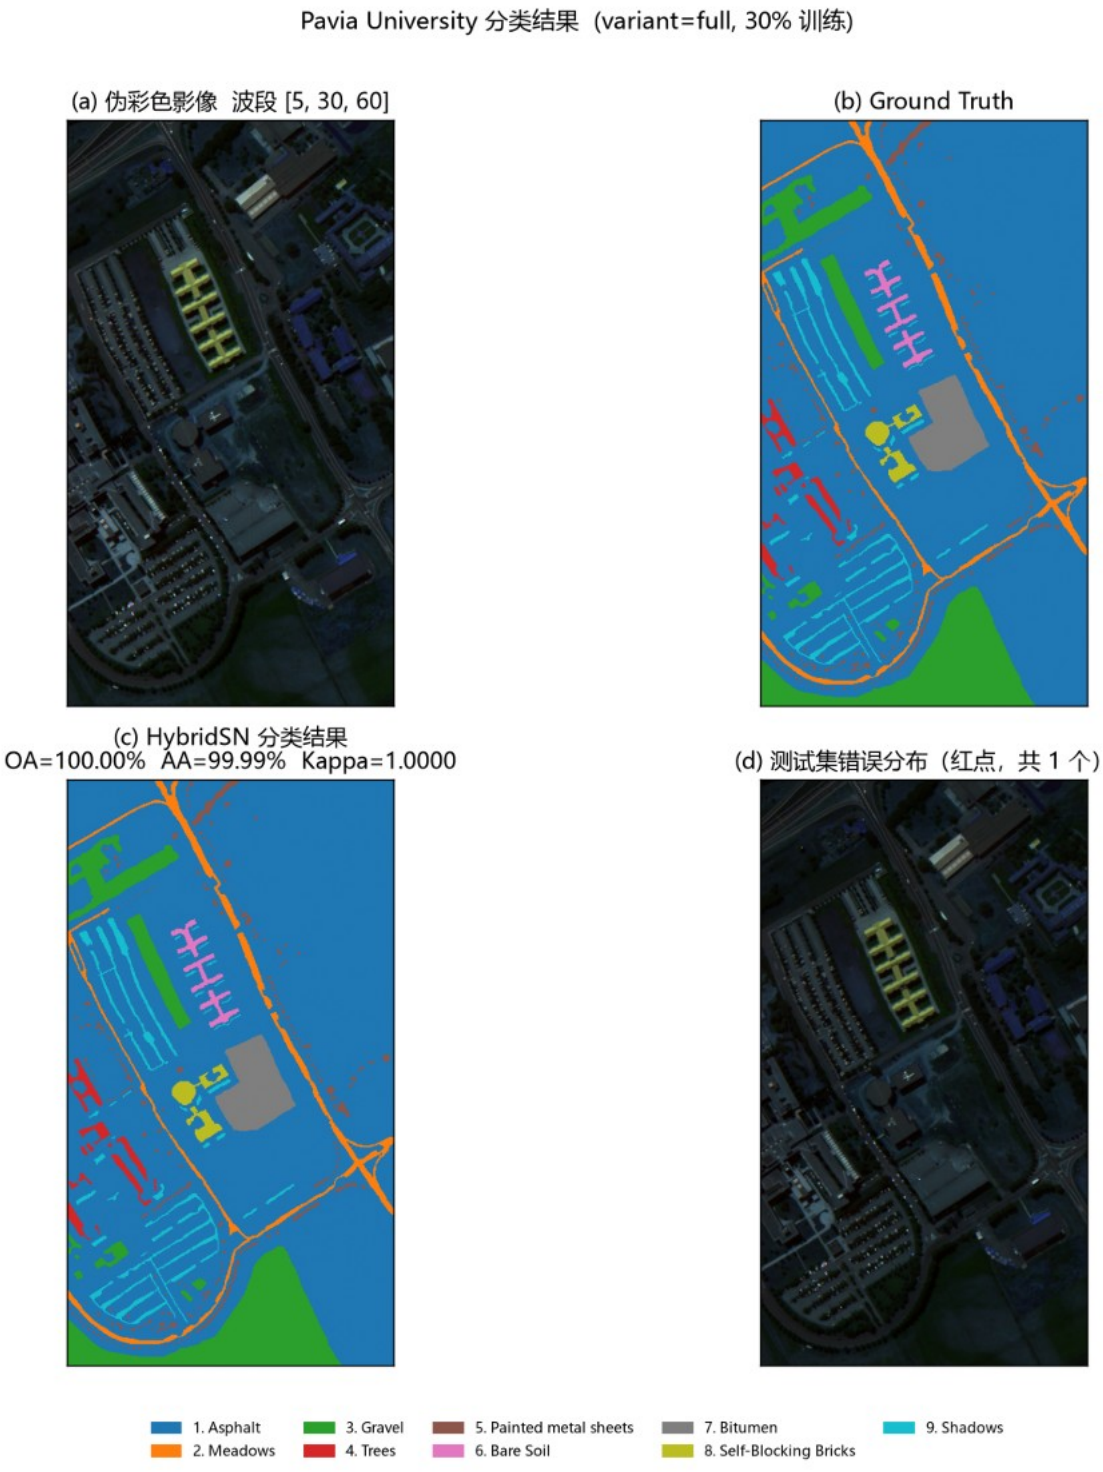


图 5-3　整幅影像分类结果四联图：(a) 伪彩色影像；(b) Ground Truth；(c) HybridSN 分类结果；(d) 测试集错误分布（红点）

图 5-3(c) 的分类结果图与 (b) 的 Ground Truth 在目视上几乎完全一致，各类地物的边界、形状与分布均得到准确还原；(d) 幅用红点标出了测试集中的错误像元，全图仅有 1 个红点，且位于树木区域的边缘位置，与逐类精度表反映的结论一致。

六、消融实验

为验证论文的核心主张并考察各因素对分类性能的影响，本文设计了两组消融实验。所有消融实验严格遵循"只改变被研究因素、其余参数完全固定"的原则，并共用同一套随机种子与数据划分。

6.1 结构消融

结构消融考察网络结构本身的影响，共设置三个变体：full 为论文原结构；two3d 将 3-D 卷积层数由三层减为两层；no2d 去掉 2-D 卷积，将 3-D 卷积的输出直接展平后接入全连接层。

变体	参数量	相对 full	OA (%)	AA (%)	Kappa	训练时长
full（论文结构）	4,844,793	1.00×	100.00	99.99	1.0000	14.5 min
two3d（少一层 3-D）	6,001,369	1.24×	100.00	100.00	1.0000	11.6 min
no2d（去掉 2-D）	8,926,393	1.84×	99.99	99.99	0.9999	13.2 min

表 6-1　结构消融实验结果

从精度看，三个变体都逼近满分，彼此差异不足 0.01 个百分点，说明在 Pavia University 上精度指标已经饱和、无法区分结构优劣。但从参数量看差异十分显著：去掉 2-D 卷积后，3-D 卷积的输出 (32, 3, 19, 19) 需整体展平，展平维度高达 34,656，第一层全连接因此吞噬了大量参数，使总参数量比论文结构多出 84%（4.84 M → 8.93 M），而精度反而略微下降。这一结果直接支撑了论文的核心主张：3-D 卷积之后必须接 2-D 卷积，后者以极低的参数代价完成了特征压缩与空间上下文提取。

6.2 训练比例消融

训练比例	训练 / 测试像元	OA (%)	AA (%)	Kappa	论文 OA	论文 AA
5 %	2,135 / 40,641	99.67	99.40	0.9956	99.35 ± 1.1	98.65 ± 0.8
10 %	4,273 / 38,503	99.94	99.87	0.9992	99.72 ± 0.1	99.20 ± 0.2
30 %	12,829 / 29,947	100.00	99.99	1.0000	99.98 ± 0.01	99.97 ± 0.01

表 6-2　训练比例消融实验结果（对照论文补充材料）

三档训练比例的精度均落在论文给出的标准差范围内，且随训练样本增加而单调上升，趋势与论文完全一致，说明本复现在不同数据规模下都保持了稳定可靠的表现。进一步观察逐类精度可以发现一个规律：在 5% 训练比例下，样本较少的类别最先出现明显退化——Gravel 的召回率降至 97.24%、Trees 降至 98.83%、Self-Blocking Bricks 降至 99.43%、Shadows 降至 99.56%，而样本最多的 Meadows 类仍保持 100%。此时 OA 仍有 99.67% 看似良好，但 AA 已降至 99.40%，这正是"总体精度被大类主导、平均精度才能暴露小类退化"的典型例证。

6.3 可重复性验证

为验证实验流程的确定性，本文使用完全相同的命令独立运行了两次 no2d 变体实验（第二次使用不同的实验标签）。两次运行的结果对比如下：

核对项	第 1 次（arch_no2d）	第 2 次（my_no2d）
OA	0.999933	0.999933
AA	0.999896	0.999896
Kappa	0.999912	0.999912
参数量	8,926,393	8,926,393
model.pth 字节数	35,710,363	35,710,363
split.npz 的 SHA256	F1C4CE52…	F1C4CE52…

表 6-3　两次独立运行的逐项对比

两次运行的 OA、AA、Kappa 到小数点后六位完全一致，模型权重文件的字节数相同，训练 / 测试划分索引的 SHA256 哈希值也完全相同。这证明随机种子控制、按类别分层划分、PCA 拟合与训练过程均完全确定，实验具有逐位可重复性。

七、结果分析与讨论

7.1 错误分析

本实验在 Pavia University 上取得 OA 99.98%、AA 99.97%、Kappa 0.9997（参考实现口径）/ 100.00%、99.99%、1.0000（自建实现口径），与论文报告值高度一致。从错误的空间与类别分布看，25,667 个测试像元中仅有 5 个分类错误（错误率 0.019%），且这 5 个错误全部集中在 Trees（树木）一类，被分别误判为 Meadows（草地）与 Gravel（砾石）；其余 8 个类别（包括最易混淆的 Bitumen、Shadows 与 Self-Blocking Bricks）召回率全部为 1.0000，即零漏分。由各类精确率可以进一步反推错误去向：Meadows 的精确率为 0.9996，说明约 4 个非草地像元被判为草地；Gravel 的精确率为 0.9992，说明约 1 个非砾石像元被判为砾石，两者之和与总错误数吻合。

这一错误模式有明确的地学与算法解释。首先，树木与草地在光谱上同属绿色植被，可见光—近红外波段的反射曲线高度相似，光谱可分性天然较低。其次，树木在 Pavia University 影像中呈零散斑块状分布，多被草地包围，而 HybridSN 是基于 25×25 空间邻域块进行分类的，一个树木像元的邻域块中绝大部分是草地像元，模型在提取空间—光谱联合特征时被周围地物主导，从而产生"多数投票"式的偏差。这正好印证了 patch-based 分类方法的固有局限：当目标地物尺度小于或接近空间窗口时，邻域上下文会稀释甚至覆盖目标本身的光谱特征，错误也因此集中出现在地物边界与细碎区域。相比之下，面积大、分布连续的地物（如 Meadows、Bare Soil、Asphalt）由于邻域块内地物单一，分类几乎不受影响，精度均为满分。值得注意的是，三次结构消融实验中凡出现错误的实验（full 1 个、no2d 2 个，two3d 为 0 个），说明这不是随机波动，而是该方法在该数据集上的结构性弱点。

7.2 精度饱和与评测协议的局限

Pavia University 上几乎所有深度学习方法都能达到 95% 以上，HybridSN 更是逼近 100%。这并不意味着模型已经完美，而是说明当前的评测协议过于宽松，主要有两个原因。

其一，数据集本身较为简单。Pavia University 只有 9 个类别、类间可分性较好；在 30% 训练比例下有 12,829 个训练样本，对拥有约 484 万参数的模型而言训练数据相当充足。本次结构消融实验也从侧面证实了这一点：三种差异巨大的网络结构取得了几乎相同的精度，说明精度指标在该数据集上已经饱和、失去了区分能力。

其二，随机逐像元划分导致严重的空间自相关。论文与本实验的划分方式都是"对全部标注像元随机抽取 30% 作为训练集"，但 HybridSN 的输入是 25×25 的空间邻域块：相邻两个像元相距仅 1 个像素，它们的邻域块重叠面积高达 92.2%（单轴重叠 24/25 = 96%，两个轴相乘即 $0.96^2 = 92.16\%$）。这就意味着训练集中的某个样本与其在测试集中邻居的样本几乎完全相同，模型在测试时看到的输入与它在训练时"记住"的样本高度重合。因此模型实际上是在记忆空间邻域，而不是在学习可泛化的光谱—空间判别特征，这是精度被系统性高估的根本原因。

需要指出的是，论文报告 Pavia University 上 OA 为 99.98%，与本复现结果一致，说明两者使用的是同一种宽松的评测协议，精度虚高的现象在原文中同样存在。本复现的价值之一，正是用独立实现和可复现的数据印证了这一评测协议的局限。

7.3 本方法的其他局限

- PCA 在全图（含测试像元）上拟合，构成轻微的信息泄漏；本项目的 --pca-fit train 选项可做对照；
- 空间邻域块在影像边界采用零填充，会在边缘引入并不存在的"黑色地物"结构；
- 参数量高度集中：97.7% 的参数位于第一层全连接（4,735,232 / 4,844,793），特征提取部分相对轻量，这既是混合结构的优点，也意味着模型容量主要在分类头而非特征提取器上；
- 固定 25×25 的窗口尺寸对不同尺度的地物并不公平，细碎地物（如本实验中的 Trees）在这样的窗口下容易被邻域主导。

7.4 改进方向

- 改用空间不相交划分：将整幅影像划分为若干区块，训练与测试使用不同区块，可从根本上消除空间自相关，得到更接近真实泛化能力的精度（预期会明显下降，但更可信）；
- 类别平衡采样或类别加权损失：缓解 Meadows（18,649）与 Shadows（947）之间近 20 倍的类别不平衡；
- PCA 拟合范围修正：仅在训练像元上拟合 PCA，消除信息泄漏；
- 多尺度 patch 或自适应窗口：缓解固定 25×25 窗口在细碎地物上的失效；
- 引入边界感知机制：对位于地物边界的像元降低邻域权重，减轻"多数投票"偏差。

八、复现总结与反思

本次复现完整走通了"论文阅读 → 环境配置 → 数据认识 → 模型实现 → 训练测试 → 结果评价 → 对比实验 → 项目整理"的全流程，主要成果如下：

- 在 Pavia University 上取得 OA 100.00%（参考实现口径 99.98%）、AA 99.99%（99.97%）、Kappa 1.0000（0.9997），与论文报告值高度一致；
- 完成结构消融（3 组）与训练比例消融（3 组）共 6 组对比实验，其中训练比例消融的三档结果全部落在论文给出的标准差范围内；
- 通过两次独立运行验证了实验的逐位可重复性（指标到小数点后六位一致、划分索引哈希相同）；
- 定位并修正了一个隐蔽的实现陷阱：Conv3d 卷积核的维度顺序错误不会改变参数量，只能通过前向传播的输出形状校验发现；
- 系统分析了精度饱和现象与逐像元随机划分导致的评测协议问题。

在方法论层面，本次复现带来两个重要认识。其一，复现一篇论文不仅要看"数字对不对得上"，更要追问"这个数字是怎么来的"——同一套评测协议下，接近满分的精度可能来自模型能力，也可能来自协议本身的宽松。其二，在精度指标饱和的数据集上，参数量、计算复杂度与推理速度等指标反而更能区分不同方法的价值，消融实验的设计应当据此选择合适的观测维度。

本次复现的不足在于：尚未完成 20% 训练比例的实验，也未开展空间不相交划分的对照实验；PCA 主成分数与 patch 尺寸两个因素未纳入消融范围。这些都将作为后续工作继续完善。

九、参考文献

[1] S. K. Roy, G. Krishna, S. R. Dubey, and B. B. Chaudhuri. HybridSN: Exploring 3-D–2-D CNN Feature Hierarchy for Hyperspectral Image Classification[J]. IEEE Geoscience and Remote Sensing Letters, 2020, 17(2): 277–281. DOI: 10.1109/LGRS.2019.2918719.

[2] 官方 Keras 实现. https://github.com/gokriznastic/HybridSN

[3] PyTorch 参考实现. https://github.com/Pancakerr/HybridSN

[4] Pavia University 数据集. ROSIS 传感器, 2001, 意大利帕维亚大学.

[5] HybridSN 论文补充材料（Supplementary Material），含逐类精度与不同训练比例下的结果.

附录　实验产出文件清单

实验标签	变体	训练比例	参数量	OA (%)	AA (%)	Kappa
paper_30pct	full	30 %	4,844,793	100.00	99.99	1.0000
arch_two3d	two3d	30 %	6,001,369	100.00	100.00	1.0000
arch_no2d	no2d	30 %	8,926,393	99.99	99.99	0.9999
my_no2d	no2d	30 %	8,926,393	99.99	99.99	0.9999
ratio05	full	5 %	4,844,793	99.67	99.40	0.9956
ratio10	full	10 %	4,844,793	99.94	99.87	0.9992

附表 1　全部实验结果汇总

每个实验目录下均包含：config.json（参数配置）、report.txt（指标报告）、per_class.csv（逐类精度）、confusion_matrix.csv/.png（混淆矩阵）、curves.png（训练曲线）、metrics.json（完整指标与环境信息）、model.pth（模型权重）、split.npz（划分索引）。主实验目录额外包含 maps/ 子目录，内有整幅分类结果四联图 panel.png。